

생성 모델 오토인코더

생성 모델

1 생성 모델이란

2 변형 오토인코더

생성 모델이란

13.1 생성 모델이란

● 생성 모델이란

- 생성 모델(generative model)은 주어진 데이터를 학습하여 데이터 분포를 따르는 유사한 데이터를 생성하는 모델
- 생성모델에서 가장 중요한 것은 **학습 데이터의 분포를 배우는 것이 제일 중요**하다고 말할 수 있다. 학습 데이터의 분포와의 차이가 적을수록 실제 데이터와 비슷한 데이터를 생성할 수 있을 것이다.

[참고:<https://wikidocs.net/151937>]

13.1 생성 모델이란

● 생성 모델 개념

- 기존 합성곱 신경망에서 다른 이미지 분류, 이미지 검출 등은 입력 이미지(x)가 있을 때 그에 따른 정답(y)을 찾는 것
- 이렇게 이미지를 분류하는 것을 '판별(자) 모델(discriminative model)'이라고 함
- 일반적으로 판별자 모델에서는 이미지를 정확히 분류(구별)하고자 해당 이미지를 대표하는 특성들을 잘 찾는 것을 목표로 함
- 예를 들어 개와 고양이를 구별하려면 개의 귀, 꼬리 등 특성을 찾는 것이 중요함

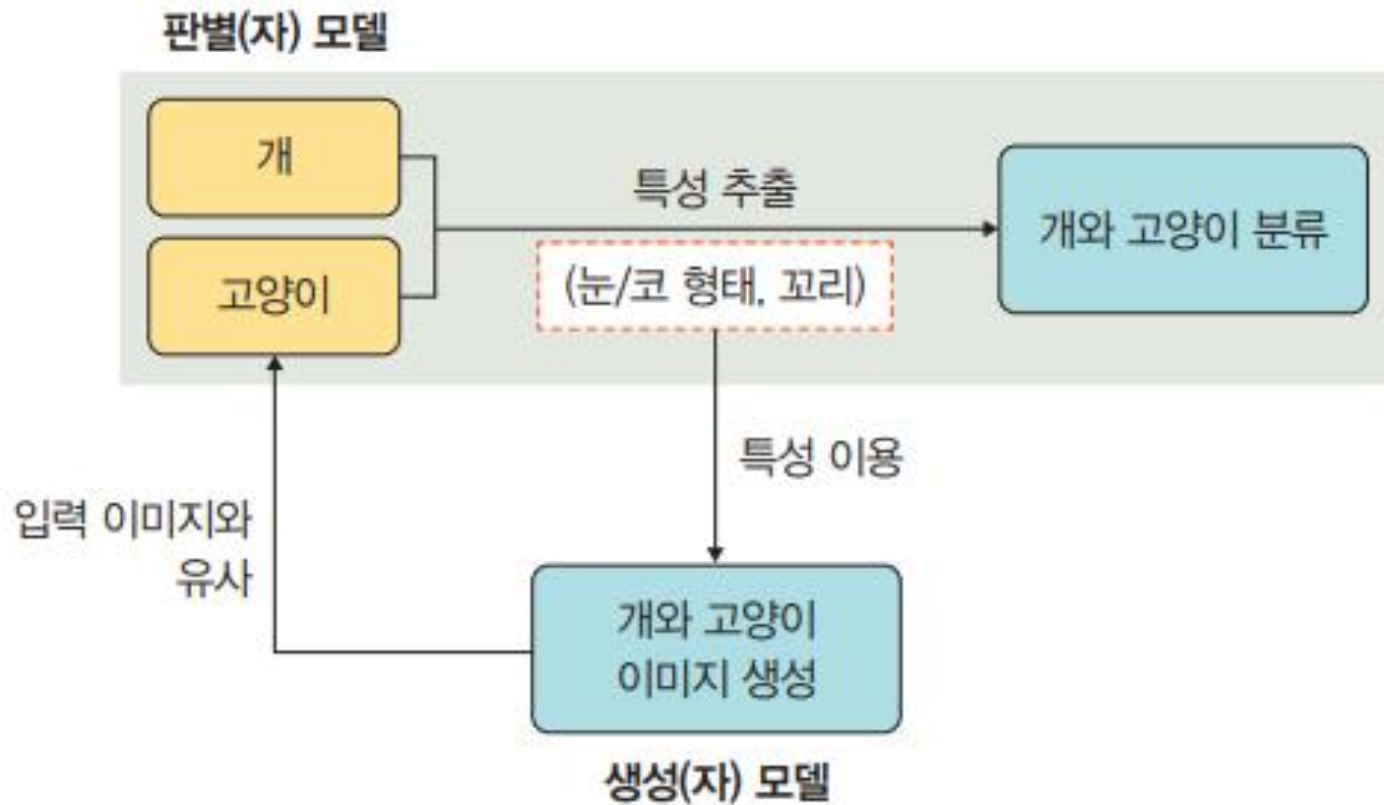
13.1 생성 모델이란

● 생성 모델 개념

- 판별자 모델에서 추출한 특성들의 조합을 이용하여 새로운 개와 고양이 이미지를 생성할 수 있는데, 이것을 '생성(자) 모델(generative model)'이라고 함
- 즉, 생성 모델은 입력 이미지에 대한 데이터 분포 $p(x)$ 를 학습하여 새로운 이미지(새로운 이미지이면서 기존 이미지에서 특성을 추출했기 때문에 최대한 입력 이미지와 유사한 이미지)를 생성하는 것을 목표로 함

13.1 생성 모델이란

▼ 그림 13-1 생성 모델

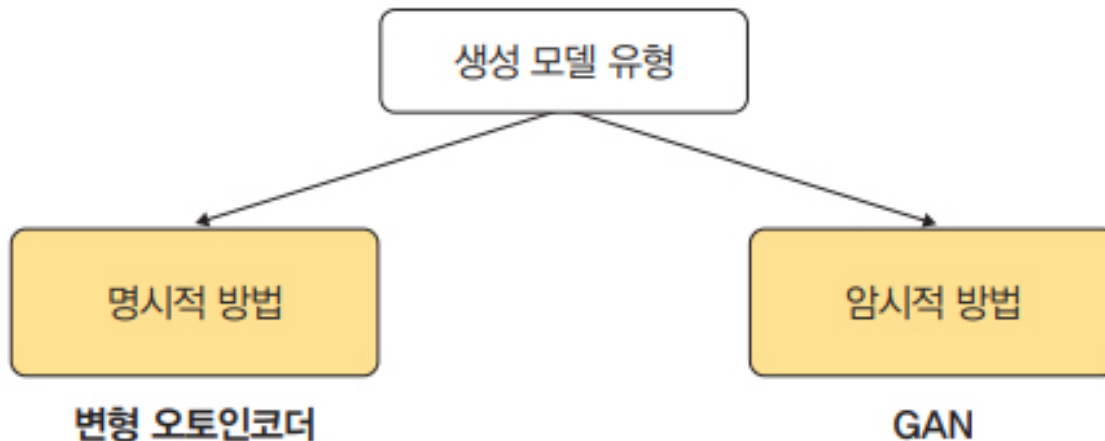


13.1 생성 모델이란

● 생성 모델의 유형

- 생성 모델의 유형에는 다음 그림과 같이 모델의 확률 변수를 구하는 '변형 오토인코더 모델'과 확률 변수를 이용하지 않는 'GAN 모델'이 있음

▼ 그림 13-2 생성 모델의 유형



13.1 생성 모델이란

● 생성 모델의 유형

- 생성 모델은 크게 명시적 방법(explicit density)과 암시적 방법(implicit density)으로 분류할 수 있음
- 명시적 방법은 확률 변수 $p(x)$ 를 정의하여 사용
- 대표적인 모델로 변형 오토인코더(variational autoencoder)가 있음
- 암시적 방법은 확률 변수 $p(x)$ 에 대한 정의 없이 $p(x)$ 를 샘플링하여 사용
- 대표적인 모델로 GAN(Generative Adversarial Network)이 있음

13.1 생성 모델이란

● 생성 모델의 유형

- 변형 오토인코더는 이미지의 잠재 공간(latent space)에서 샘플링하여 완전히 새로운 이미지나 기존 이미지를 변형하는 방식으로 학습을 진행
- GAN은 생성자와 판별자가 서로 경쟁하면서 가짜 이미지를 진짜 이미지와 최대한 비슷하게 만들도록 학습을 진행

13.2 변형 오토인코더

13.2 변형 오토인코더

● 변형 오토인코더

- 변형 오토인코더는 오토인코더의 확장
- 오토인코더가 무엇인지 확인한 후 변형 오토인코더 학습

EdgesCats Demo pix2pix-tensorflow

<https://affinelayer.com/pixsrv/>

13.2 변형 오토인코더

● 오토인코더란

- 오토인코더는 단순히 입력을 출력으로 복사하는 신경망으로 은닉층(혹은 병목층이라고도 함)의 노드 수가 입력 값보다 적은 것이 특징
- 입력과 출력이 동일한 이미지라고 예상할 수 있음
- 왜 입력을 출력으로 복사하는 방법을 사용할까?
- 바로 은닉층 때문임
- 오토인코더의 병목층은 입력과 출력의 뉴런보다 훨씬 적음
- 즉, 적은 수의 병목층 뉴런으로 데이터를 가장 잘 표현할 수 있는 방법이 오토인코더

13.2 변형 오토인코더

● 오토인코더란

- 오토인코더는 네 가지 주요 부분으로 구성

1. 인코더: 인지 네트워크(recognition network)라고도 하며, 특성에 대한 학습을 수행하는 부분

2. 병목층(은닉층): 모델의 뉴런 개수가 최소인 계층

이 계층에서는 차원이 가장 낮은 입력 데이터의 압축 표현이 포함

3. 디코더: 생성 네트워크(generative network)라고도 하며, 이 부분은 병목층에서 압축된 데이터를 원래대로 재구성(reconstruction)하는 역할을 함

즉, 최대한 입력에 가까운 출력을 생성하도록 함

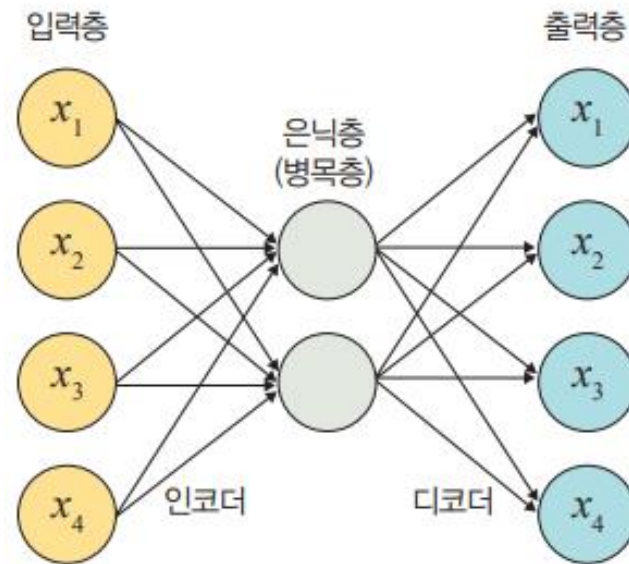
13.2 변형 오토인코더

● 오토인코더란

4. 손실 재구성: 오토인코더는 다음 그림과 같이 입력층과 출력층의 뉴런 개수가 동일하다는것만 제외하면 일반적인 다층 퍼셉트론(Multi-Layer Perceptron, MLP)과 구조가 동일

오토인코더는 압축된 입력을 출력층에서 재구성하며, 손실 함수는 입력과 출력(인코더와 디코더)의 차이를 가지고 계산

▼ 그림 13-3 오토인코더



오토인코더 (스택 오토인코더)

```
import torch
import torchvision
from torchvision import transforms
import torch.nn.functional as F
import torch.nn as nn
import torch.optim as optim
import numpy as np
import matplotlib.pyplot as plt
```


오토인코더 (스택 오토인코더)

```
# CPU/GPU
```

```
device = torch.device("cuda:0" if  
torch.cuda.is_available() else "cpu")  
print(f'{device} is available.')
```

```
dataset =  
torchvision.datasets.MNIST('./data/',  
download=True, train=True,  
transform=transforms.ToTensor())  
trainloader =  
torch.utils.data.DataLoader(dataset, batch_s  
ize=50, shuffle=True)
```



```
dataset = torchvision.datasets.MNIST('./data/', download=True, train=True, transform=transforms.ToTensor())  
trainloader = torch.utils.data.DataLoader(dataset, batch_size=50, shuffle=True)
```



Downloading <http://yann.lecun.com/exdb/mnist/train-images-idx3-ubyte.gz>

Downloading <http://yann.lecun.com/exdb/mnist/train-images-idx3-ubyte.gz> to ./data/MNIST/raw/train-images-idx3-ubyte.gz

100%|██████████| 9912422/9912422 [00:00<00:00, 81198437.67it/s]

Extracting ./data/MNIST/raw/train-images-idx3-ubyte.gz to ./data/MNIST/raw

Downloading <http://yann.lecun.com/exdb/mnist/train-labels-idx1-ubyte.gz>

Downloading <http://yann.lecun.com/exdb/mnist/train-labels-idx1-ubyte.gz> to ./data/MNIST/raw/train-labels-idx1-ubyte.gz

100%|██████████| 28881/28881 [00:00<00:00, 102570443.54it/s]

Extracting ./data/MNIST/raw/train-labels-idx1-ubyte.gz to ./data/MNIST/raw

Downloading <http://yann.lecun.com/exdb/mnist/t10k-images-idx3-ubyte.gz>

Downloading <http://yann.lecun.com/exdb/mnist/t10k-images-idx3-ubyte.gz> to ./data/MNIST/raw/t10k-images-idx3-ubyte.gz

100%|██████████| 1648877/1648877 [00:00<00:00, 24152388.02it/s]

Extracting ./data/MNIST/raw/t10k-images-idx3-ubyte.gz to ./data/MNIST/raw

Downloading <http://yann.lecun.com/exdb/mnist/t10k-labels-idx1-ubyte.gz>

Downloading <http://yann.lecun.com/exdb/mnist/t10k-labels-idx1-ubyte.gz> to ./data/MNIST/raw/t10k-labels-idx1-ubyte.gz

100%|██████████| 4542/4542 [00:00<00:00, 18768993.86it/s] Extracting ./data/MNIST/raw/t10k-labels-idx1-ubyte.gz to ./data/MNIST/raw

```
[16] class Autoencoder(nn.Module):  
    def __init__(self):  
        super(Autoencoder, self).__init__()  
        self.encoder = nn.Sequential(  
            nn.Linear(784, 128),  
            nn.ReLU(),  
            nn.Linear(128, 32),  
            nn.ReLU(),  
            nn.Linear(32, 10),  
            nn.ReLU()  
        )  
        self.decoder = nn.Sequential(  
            nn.Linear(10, 32),  
            nn.ReLU(),  
            nn.Linear(32, 128),  
            nn.ReLU(),  
            nn.Linear(128, 28*28)  
            #nn.Sigmoid()  
        )  
  
    def forward(self, x):  
        encoded = self.encoder(x)  
        decoded = self.decoder(encoded)  
        return decoded
```

```
model = Autoencoder().to(device)

def normalize_output(img):
    img = (img - img.min()) / (img.max() - img.min())
    return img

def check_plot():
    with torch.no_grad():
        for data in trainloader:

            inputs = data[0].to(device)
            outputs = model(inputs.view(-1, 28*28))
            outputs = outputs.view(-1, 1, 28, 28)

            input_samples = inputs.permute(0, 2, 3, 1).cpu().numpy()
# 원래 이미지
            reconstructed_samples = outputs.permute(0, 2, 3, 1).cpu().numpy()
# 생성 이미지
            break
```

```
columns = 10 # 시각화 전체 너비
```

```
rows = 5 # 시각화 전체 높이
```

```
fig=plt.figure(figsize=(columns, rows)) # figure 선언
```

```
for i in range(1, columns*rows+1):
```

```
    img = input_samples[i-1]
```

```
    fig.add_subplot(rows, columns, i)
```

```
    plt.imshow(img.squeeze())
```

```
    plt.axis('off')
```

```
plt.show()
```

```
plt.close()
```

```
fig=plt.figure(figsize=(columns, rows))
```

```
for i in range(1, columns*rows+1):
```

```
    img = reconstructed_samples[i-1]
```

```
    fig.add_subplot(rows, columns, i)
```

```
    plt.imshow(img.squeeze())
```

```
    plt.axis('off')
```

```
plt.show()
```

```
criterion = nn.MSELoss() # MSE 사용  
optimizer = optim.Adam(model.parameters(),  
lr=1e-4)
```

```
for epoch in range(51):

    running_loss = 0.0
    for data in trainloader:
        inputs = data[0].to(device)
        optimizer.zero_grad()
        outputs = model(inputs.view(-1, 28*28))
        outputs = outputs.view(-1, 1, 28, 28)
        loss = criterion(inputs, outputs)
        # 라벨 대신 입력 이미지와 출력 이미지를 비교
        loss.backward()
        optimizer.step()
        running_loss += loss.item()

    cost = running_loss / len(trainloader)
    print('[%d] loss: %.3f' % (epoch + 1, cost))
```

✓
9분


[17]

```
[43] loss: 0.023  
[44] loss: 0.023  
[45] loss: 0.023  
[46] loss: 0.023  
[47] loss: 0.023  
[48] loss: 0.023  
[49] loss: 0.023  
[50] loss: 0.023  
[51] loss: 0.023
```

✓
3초



check_plot()



감사합니다.